Relatório Técnico: Base de Conhecimento, Protótipo de RAG e Telemetria

RES IA ELD UNB — Turma 2 | Grupo 7 — Orquestrador de Rolês (Brasília/DF)

Equipe: Letícia Miti Takahashi (Engenharia de Dados & RAG) e Maria Eduarda (DevOps, Infraestrutura & LLMOps)

Prazo Oficial: 09/11/2026, às 08h00 | **App Online:** orquestrador-roles.onrender.com | **Telemetria:** Langfuse Cloud

1. Resumo Executivo e Checklist dos Artefatos

O objetivo deste entregável da Semana 2 é construir e auditar o mecanismo de **RAG (*Retrieval-Augmented Generation*)** fundamentado em base de conhecimento curada de Brasília, assegurando alta precisão na recuperação semântica, geração fundamentada sem alucinações e rastreabilidade ponta a ponta das fontes.

Requisito do Edital	Status	Localização no Repositório	Resumo Técnico
1. Base curada	**Concluído**	`data/banco_aprovado_2fa.json` e `.csv`	93 estabelecimentos aprovados pelo protocolo 2FA.
2. Mínimo 20 fontes	**Superado**	`data/banco_aprovado_2fa.json` (93 fontes)	164 vídeos auditados de 2026 (`@rolezandoembrasilia`).
3. Estratégia chunking	**Concluído**	Seção 2 + `src/rag/banco_vetorial.py`	*Entity-Centric Semantic Chunking* (1 chunk por local).
4. Embeddings	**Concluído**	Seção 3 + `src/rag/banco_vetorial.py`	`models/gemini-embedding-001` (3.072-d) + Cosseno.
5. Banco vetorial	**Concluído**	`data/banco_vetorial_embeddings.json`	93 vetores persistidos com busca top-K ($K = 3$).
6. Demonstração RAG	**Concluído**	`src/rag/prototipo_rag.py` + `.txt`	4 passos: Consulta → Chunks → Resposta → Fontes.
7. Diagrama & Pipeline	**Concluído**	Seções 4 e 5 deste relatório	Fluxos de Ingestão 2FA e Arquitetura de Runtime RAG.
8. Telemetria LLMOps	**Concluído**	Seção 6 + `src/telemetria/telemetria.py`	Langfuse Cloud v5.x (Auditoria RNF-03 e RNF-14).

2. Estratégia de Chunking (*Entity-Centric Semantic Chunking*)

2.1. Por que não utilizar *Fixed-Size Chunking*?

Vídeos curtos de gastronomia e lazer (30 a 60 segundos) apresentam estrutura narrativa não linear: o **nome do local** é citado na abertura, as **vibes e pratos** no desenvolvimento e o **preço e endereço** nos segundos finais. Um particionamento cego por janela fixa de caracteres ou tokens separaria o endereço e o preço do nome do estabelecimento, gerando *context fragmentation* e induzindo alucinações cruzadas durante a síntese da resposta.

2.2. Solução Adotada: 1 Documento-Fonte = 1 Chunk Semântico Autocontido

Cada estabelecimento aprovado consolida 4 camadas de informação validadas em um único bloco textual coeso (média de 450 a 750 caracteres, ~ 120 a 190 tokens), garantindo que o vetor represente a totalidade semântica do rolê:

1. **Identidade e Categoria (Fator 1):** Nome oficial do estabelecimento e classificação estruturada (`Restaurante`, `Bar/Pub`, `Cafeteria`, `Experiência/Evento`, `Ao Ar Livre`).
2. **Ancoragem Geoespacial e Financeira (Fator 2):** Região Administrativa (RA) do DF, endereço completo validado via OpenStreetMap/Nominatim, coordenadas GPS (`lat/lon`) e faixa de preço (`Barato $`, `Moderado $$`, `Caro $$$`) com ticket médio em R$.
3. **Atmosfera e Cultura (Fator 1):** Tags de *Vibes* (`Romântico`, `Calmo`, `Baratinho`, `Alternativo`, `Kid Friendly`, `Animado`) combinadas ao Resumo Sensorial da experiência.
4. **Evidência Oral Bruta (Whisper ASR):** Trecho literal da transcrição de áudio do vídeo (até 500 caracteres), preservando termos específicos do cardápio e atrações (ex.: *"rodízio"*, *"parrilla"*, *"brinquedoteca"*, *"música ao vivo"*).

Template Estruturado do Chunk Indexado no Banco Vetorial

```
Local: {nome} | Categoria: {tipo} | Região: {RA} ({endereco}) | Preço: {faixa} (R$ {custo_medio}) | Vibes: {vibes} | Experiência: {resumo_sensorial} | TikTok: {transcricao_whisper_500c}
```

3. Estratégia de Embeddings e Banco Vetorial

A indexação semântica e a recuperação densa foram implementadas em `src/rag/banco_vetorial.py` com as seguintes especificações técnicas:

- **Modelo de Embedding:** `models/gemini-embedding-001` (Google Generative Language API).
- **Dimensionalidade: 3.072 dimensões** (vetores densos de alta resolução sem truncamento).
- **Justificativa Técnica:** O modelo apresenta forte alinhamento semântico em Português Brasileiro e expressões coloquiais/regionais de Brasília, associando intenções abstratas aos atributos corretos sem depender de casamento exato de palavras (ex.: associar *"passeio ao ar livre com criança gastando pouco"* a *"Eixão do Lazer / Kid Friendly / Gratuito"*).
- **Métrica de Busca e Ranking:** Similaridade de Cosseno calculada entre o vetor da consulta ($\vec{q}$) e cada um dos $N = 93$ vetores indexados ($\vec{d_i}$), retornando o Top-K ($K = 3$) de maior escore:

$$\text{Similaridade}(\vec{q}, \vec{d_i}) = \frac{\vec{q} \cdot \vec{d_i}}{\|\vec{q}\| \, \|\vec{d_i}\|} = \frac{\sum_{j=1}^{3072} q_j \, d_{i,j}}{\sqrt{\sum_{j=1}^{3072} q_j^2} \sqrt{\sum_{j=1}^{3072} d_{i,j}^2}}$$

- **Persistência e Portabilidade:** Os 93 vetores de 3.072 coordenadas estão persistidos em `data/banco_vetorial_embeddings.json` (5.9 MB) e `.csv`, permitindo carregamento instantâneo em memória com latência de busca na casa de milissegundos.

4. Pipeline de Ingestão de Dados (Curadoria em 2 Fatores — 2FA)

Para impedir que vídeos patrocinados fora de escopo (como óticas ou lojas de colchões) ou estabelecimentos sem endereço/preço contaminassem o RAG, foi construído o pipeline automatizado de **Autenticação de Dois Fatores de Dados (2FA)** em `src/rag/coletor_tiktok_2fa.py`:

Etapa 1 — Coleta & ASR	**164 vídeos brutos (safra 2026)** do perfil `@rolezandoembrasilia` → Extração de áudio MP3 (`yt-dlp` + `curl_cffi`) → Transcrição via Groq (`whisper-large-v3-turbo`).
Etapa 2 — FATOR 1 (Cultural)	**Filtro Semântico via LLM:** Avalia se o vídeo retrata um local real de gastronomia/lazer. • *Reprovados (47 vídeos):* Propaganda de varejo/serviços descartada automaticamente. • *Aprovados (117 vídeos):* Extração estruturada de Nome, Categoria (5 tipos) e Vibes (7 tags).
Etapa 3 — FATOR 2 (Prático)	**Dupla Trava Geográfica e Financeira:** Exige Endereço no DF (validado via GPS Nominatim) + Preço (R$). • *Incompletos (24 vídeos):* Retidos em quarentena auditável (`data/fila_quarentena_2fa.json`). • *Aprovados nas 2 Travas (**93 fontes**):* Promovidos à Base Curada (`data/banco_aprovado_2fa.json`).
Etapa 4 — Indexação Vetorial	**Chunking & Embeddings:** Montagem dos 93 chunks autocontidos → Geração de vetores densos de 3.072 dimensões (`gemini-embedding-001`) → Persistência em `data/banco_vetorial_embeddings.json`.

5. Arquitetura do Sistema e Telemetria em Tempo de Execução

O fluxo em tempo de execução (*Runtime RAG*) opera integrado ao SDK do **Langfuse Cloud (v5.x / OpenTelemetry)**, registrando cada etapa de recuperação e geração:

1. Consulta & Vetorização	2. Busca Vetorial (Top-3)	3. Geração Fundamentada
A pergunta em linguagem natural é convertida em um vetor de 3.072 dimensões via `gemini-embedding-001`.	Cálculo de Similaridade de Cosseno contra os 93 vetores curados, retornando os 3 chunks mais aderentes.	A LLM sintetiza a recomendação estritamente ancorada nos chunks, citando `[FONTE #1]` e links do TikTok.

Camada Transversal de Observabilidade (Langfuse Cloud v5.x / OpenTelemetry): Rastreamento automático dos spans `retriever` e `generation` com cálculo e envio em tempo real dos scores de governança: `fidelidade_rnf03_zero_alucinacao = 1.0`, `sla_latencia_rnf14 <= 5.0s` e `qualidade_recuperacao_rag`.

6. Telemetria, Observabilidade e Auditoria de RNFs (Langfuse Cloud)

A instrumentação ponta a ponta implementada em `src/telemetria/telemetria.py` audita matematicamente o pipeline a cada requisição submetida na API ou na interface web:

1. `fidelidade_rnf03_zero_alucinacao` **(Meta: Zero Alucinação) — Score Obtido: 1.0 (100% ancorado):** O validador verifica se todos os estabelecimentos recomendados pertencem estritamente aos 93 documentos homologados em `data/banco_aprovado_2fa.json`, bloqueando invenções fora da base.
2. `sla_latencia_rnf14` **(Meta ≤ 5.0 s) — Score Obtido: 1.0 (Conforme):** Latência de processamento e recuperação vetorial entre **2.8 ms e 21.9 ms**, operando com ampla margem de segurança para experiência conversacional fluida.
3. `qualidade_recuperacao_rag` **(Relevância Semântica) — Score Obtido: 0.87 a 0.98:** Atesta alta precisão no casamento entre a intenção do usuário e os metadados/transcrições de áudio.

6.1. Casos de Teste Auditados com Traces Rastreáveis no Langfuse

ID	Consulta Submetida	1º Recuperado	Região	Cosseno	Latência	Trace ID (Langfuse)
#1	*"Qual o melhor boteco alternativo e animado na Asa Sul?"*	**Spelunca DF**	Asa Sul	**0.98**	21.9 ms	`ac2ece1889e84b72`
#2	*"Quero um café romântico e calmo na Asa Norte"*	**Café e Um Chêro**	Asa Norte	**0.98**	5.5 ms	`2fe411a5e04f46ab`
#3	*"Opção ao ar livre, baratinha e kid friendly para domingo"*	**Eixão do Lazer**	Eixo Rodov.	**0.87**	2.8 ms	`0a0f08b4188045f1`

6.2. Análise Técnica e Qualitativa dos Resultados

- **Desambiguação Geográfica e de Categoria (Caso #1):** Ao solicitar *"boteco alternativo na Asa Sul"*, o buscador descartou bares de outras regiões e cafeterias, priorizando o *Spelunca DF* (Score 0.98) pelo casamento simultâneo de categoria (`Bar/Pub`), vibe (`Alternativo/Animado`) e região (`Asa Sul`).
- **Captura de Nuances de Atmosfera (Caso #2):** A transcrição oral do Whisper preservou expressões sobre ambiente acolhedor e tranquilo para conversa a dois, assegurando que o *Café e Um Chêro* (Asa Norte) atingisse 0.98 de similaridade.
- **Combinação Multifatorial (Caso #3):** A busca cruzou espaço aberto, baixo custo (*baratinha*) e adequação infantil, ativando as tags `Ao Ar Livre`, `Baratinho` e `Kid Friendly` para ranquear o *Eixão do Lazer* em 1º lugar.

6.3. Governança de Custos e Consumo de Tokens (RNF-15)

- **Consumo Médio por Consulta:** ~ 280 tokens de entrada (Prompt de sistema + Top-3 Chunks) e ~ 65 tokens de saída (Resposta fundamentada com fontes).
- **Custo Estimado por Requisição: $0.000045 USD** utilizando o modelo Google Gemini 1.5 Flash, permitindo mais de 30.000 consultas mensais dentro da cota gratuita sem ônus financeiro para a UnB ou para o Instituto Eldorado.

7. Demonstração e Como Testar o Protótipo

7.1. Opção 1: Demonstração Online Direta no Navegador (Recomendada)

Acesse a aplicação publicada em nuvem: **https://orquestrador-roles.onrender.com** (clique em **"Acessar RAG →"** para abrir `/rag`).

- Permite submeter consultas livres, visualizar os cards fundamentados com links diretos para os vídeos do TikTok, inspecionar os scores de RNF e abrir o trace correspondente no Langfuse Cloud em tempo real.

7.2. Opção 2: Bateria de Testes Reprodutível via Terminal

Na raiz do repositório, execute o comando abaixo (ou utilize `./scripts/iniciar_mac_linux.sh` / `scripts\iniciar_windows.bat`):

```
python3 src/rag/prototipo_rag.py
```

O script executa automaticamente os **4 passos obrigatórios da avaliação**: **(1)** Exibe a consulta submetida; **(2)** Exibe os Top-3 Chunks recuperados com seus scores de cosseno; **(3)** Exibe a resposta fundamentada da LLM citando `[FONTE #1]`, `[FONTE #2]`; e **(4)** Lista a evidência completa das fontes (ID, coordenadas GPS, preço validado, transcrição Whisper e link original do TikTok). O log integral encontra-se salvo em `docs/entregas/semana-02/DEMONSTRACAO_RAG_ENTREGAVEL.txt`.

8. Preparação para a Semana 3 (Baseline LLM Pura vs. RAG)

Conforme o cronograma pedagógico do Challenge 2, a **Semana 3** terá como foco a comparação empírica entre respostas geradas sem contexto (*LLM pura / Zero-Shot*) e respostas ancoradas (*RAG fundamentado em evidências*). A base de 93 estabelecimentos homologados pelo protocolo 2FA e a telemetria ativa no Langfuse já estabelecem a **linha de base quantitativa (*Baseline*)** para o experimento.

8.1. Metodologia do Benchmark Comparativo (*Golden Dataset*)

Foi estruturada uma bateria padronizada de 10 prompts de avaliação cobrindo diferentes níveis de especificidade regional no Distrito Federal:

1. **Consultas de Nicho Local:** Testar estabelecimentos e eventos específicos de Brasília para quantificar a taxa com que a LLM pura inventa quadras inexistentes ou recomenda locais encerrados.
2. **Consultas com Restrições de Orçamento e Funcionamento:** Verificar a precisão dos valores médios em reais (R$) e recortes de horário/dia (ex.: lazer gratuito aos domingos ou opções até R$ 35,00 em Taguatinga e Águas Claras).
3. **Avaliação Automatizada no Langfuse (*LLM-as-a-Judge*):** Cada par de saídas (*LLM Pura* vs. *RAG*) será pontuado segundo três dimensões:
   - **Fidelidade Factual (*Hallucination Rate*):** Proporção de afirmações verificáveis na base 2FA;
   - **Precisão Geoespacial:** Validação de quadra, bloco e Região Administrativa (RA);
   - **Rastreabilidade (*Source Attribution*):** Presença de evidência primária verificável (link de vídeo e transcrição).

8.2. Matriz de Tratamento de Casos de Borda e Guardrails do RAG

Cenário de Borda	Comportamento do Buscador	Mecanismo de Salvaguarda (Guardrail)
Consulta Fora de Escopo *(ex.: "Jantar em Copacabana?")*	Similaridade de cosseno máxima fica abaixo do limiar de corte (Score < 0.65).	O orquestrador recusa alucinar locais fora da base e informa que o escopo é exclusivo do Distrito Federal.
Restrições Conflitantes *(ex.: "Alta gastronomia grátis")*	Recupera locais com semântica de gastronomia sofisticada, mas inspeciona o campo `faixa_preco`.	A resposta explicita a faixa de preço real cadastrada (`$$$`) e sugere alternativas econômicas reais.
Gírias Regionais Candangas *(ex.: "rolê na tesourinha / eixão")*	O embedding de 3.072 dimensões associa o vocabulário coloquial transcrito pelo Whisper à geografia local.	Garante recuperação semântica robusta mesmo quando o usuário utiliza expressões informais de Brasília.

9. Conclusão e Links de Acesso ao Ecossistema

A entrega da Semana 2 cumpre integralmente todos os critérios técnicos e avaliativos do Segundo Desafio: **volume curado superado** (93 fontes validadas contra o mínimo exigido de 20), **chunking semântico livre de fragmentação**, **embeddings densos de 3.072 dimensões**, **geração 100% ancorada com citação de fontes**, **observabilidade em tempo real no Langfuse Cloud** e **sustentabilidade financeira comprovada**.

Recurso do Projeto	Ambiente / Tipo	Endereço Direto / Caminho no Repositório
Aplicação Web (Landing Page)	Produção (Render)	`https://orquestrador-roles.onrender.com`
Interface Interativa do RAG	Produção (Render)	`https://orquestrador-roles.onrender.com/rag`
Painel Langfuse (Telemetria)	Langfuse Cloud v5	`Projeto cmw59be2y01d8ad0jqbgsjut6`
Log de Demonstração (4 Passos)	Repositório Git	`docs/entregas/semana-02/DEMONSTRACAO_RAG_ENTREGAVEL.txt`
Pacote Compactado da Entrega	Arquivo ZIP	`docs/entregas/semana-02/Entregavel_Grupo7_Base_Conhecimento_e_RAG.zip`