INSTITUTO DE PESQUISAS ELDORADO
UNIVERSIDADE DE BRASÍLIA
RESIDÊNCIA EM INTELIGÊNCIA ARTIFICIAL – TURMA 2
GRUPO 07

LETÍCIA MITI TAKAHASHI – CIENTISTA DE DADOS
MARIA EDUARDA – ML/LLMOPS & DEVOPS
MARIA CAROLINA – ENGENHARIA DE DADOS
CAUAN SOARES – ARQUITETO DA SOLUÇÃO
SAMARA LETÍCIA – ENGENHARIA DE DADOS

ORQUESTRADOR DE ROLÊS (DISTRITO FEDERAL)
RELATÓRIO TÉCNICO: BASE DE CONHECIMENTO CURADA E PROTÓTIPO DE RAG

Definições e Resultados – Challenge 2, Semana 2

1 VISÃO GERAL E RESUMO DOS ENTREGÁVEIS

O presente relatório técnico documenta a concepção, o pipeline de ingestão automatizada de dados, a estratégia de segmentação semântica (*chunking*), a modelagem de *embeddings* vetoriais, a governança de observabilidade (*LLMOps*) e a demonstração experimental do mecanismo de Geração Aumentada por Recuperação (*Retrieval-Augmented Generation* – RAG) desenvolvido pelo Grupo 07 no âmbito do Challenge 2 da Residência em Inteligência Artificial (Universidade de Brasília e Instituto de Pesquisas Eldorado).

O sistema Orquestrador de Rolês tem como propósito apoiar grupos de amigos no Distrito Federal no planejamento de encontros presenciais, mitigando barreiras de constrangimento financeiro, sobrecarga de decisão e dispersão de informações. Para que as recomendações do agente inteligente sejam confiáveis, o sistema exige uma base de conhecimento factual rigorosa, imune a alucinações e ancorada em estabelecimentos reais, com valores monetários e localizações geográficas auditadas.

O Quadro 1 resume o atendimento a todos os requisitos estipulados para a entrega da Semana 2, associando cada item à sua implementação técnica e respectivo artefato no repositório.

Quadro 1 – Conformidade dos requisitos da Semana 2

Requisito do Edital	Implementação Técnica	Artefato no Projeto
1. Base de conhecimento curada	Curadoria em Dois Fatores (2FA) com validação cultural e dupla trava	data/banco_aprovado_2fa.json e data/banco_aprovado_2fa.csv
2. Mínimo de 20 documentos-fonte	93 documentos homologados (extraídos de 164 vídeos de 2026)	data/banco_aprovado_2fa.json (93 itens aprovados)
3. Estratégia de chunking	Chunking Semântico Centrado em Entidade (1 chunk autocontido)	Seção 3 deste relatório e módulo src/rag/banco_vetorial.py
4. Estratégia de embeddings	Modelo de 3.072 dimensões com busca por similaridade de cosseno	Seção 4 deste relatório e banco_vetorial_embeddings.json
5. Banco vetorial implementado	Persistência em JSON/CSV e motor vetorial com busca Top-3	data/banco_vetorial_embeddings.json e banco_vetorial.py
6. Demonstração dos 4 passos	Bateria com consulta, chunks, resposta fundamentada e fontes	prototipo_rag.py e arquivo DEMONSTRACAO_RAG_ENTREGAVEL.txt
7. Telemetria e LLMOps	Rastreamento em tempo real, cálculo de SLA e fidelidade no Langfuse	src/telemetria/telemetria.py e painel Langfuse Cloud v5.x
8. Interface interativa	Central web para exploração de dados, relatórios e testes	https://orquestrador-roles.onrender.com/entregaveis

Fonte: elaborado pelos autores (2026).

2 PIPELINE DE INGESTÃO E CURADORIA EM DOIS FATORES (2FA)

A construção da base de conhecimento fundamentou-se na extração integral dos vídeos publicados ao longo do ano de 2026 pelo canal especializado em gastronomia, entretenimento e turismo local @*rolezandoembrasilia* na plataforma TikTok, totalizando 164 registros multimídia brutos.

Em redes sociais, publicações em vídeo frequentemente omitem informações textuais relevantes nas legendas, reservando dados cruciais de preços, endereços e pratos à locução em áudio falado. Adicionalmente, canais de turismo intercalam recomendações genuínas com publicidades patrocinadas de segmentos dissociados do lazer (como óticas, comércio de vestuário e serviços de saúde).

Para assegurar a integridade da base e cumprir o requisito de não alucinação (RNF-03), foi desenvolvido no módulo *coletor_tiktok_2fa.py* um pipeline de Autenticação de Dois Fatores de Dados (2FA), composto por cinco etapas sequenciais:

a) **Coleta Bruta e Extração de Mídia:** Descoberta automatizada de identificadores de vídeo via identificador seguro (*secUid*) utilizando as bibliotecas *yt-dlp* e *curl_cffi*, com extração dos metadados públicos e download do fluxo de áudio em formato MP3 de todos os 164 vídeos de 2026.

b) **Transcrição Automática de Fala (ASR):** Conversão da trilha de áudio em texto pelo modelo Whisper Large v3 Turbo, hospedado na infraestrutura de alta velocidade da Groq API. O processo recuperou detalhes citados exclusivamente pelos narradores, tais como valores monetários, formatos de atendimento e pontos de referência no Distrito Federal.

c) **Fator 1 (Curadoria Cultural e Tipológica):** Processamento do texto transcrito por meio de modelo de linguagem (*LLM*) instruído com esquema estrito. O filtro descartou automaticamente 47 vídeos de publicidade comercial (lojas de roupas, óticas e colchões) e extraiu estruturadamente: nome oficial, tipo de rolê (classificado em Restaurante/Gastronomia, Bar/Boteco/Pub, Cafeteria/Doceria, Ao Ar Livre/Parque ou Experiência/Evento) e perfil sensorial/vibes (Romântico/Date, Calmo/Bom para Conversar, Intimista/Aconchegante, Baratinho, Cultural/Alternativo, Kid Friendly e Animado/Galera).

d) **Fator 2 (Validação Prática por Dupla Trava):** Submissão dos candidatos a duas regras determinísticas de conformidade:

   - *Trava 1 (Geolocalização no DF):* Exigência de confirmação de logradouro válido em uma das Regiões Administrativas do Distrito Federal e coordenadas de latitude e longitude verificáveis.
   - *Trava 2 (Orçamento Objetivo):* Exigência de valor monetário médio explícito por pessoa (em Reais) e enquadramento em faixa de custo (Barato, Moderado ou Caro).

   Os registros que falharam em qualquer uma das duas travas (24 vídeos com ausência de preço exato ou sem endereço pontual) foram encaminhados à fila de quarentena (*data/fila_quarentena_2fa.json*). Os 93 estabelecimentos aprovados simultaneamente em ambos os fatores integraram a base oficial (*data/banco_aprovado_2fa.json*).

e) **Vetorização e Indexação:** Geração dos chunks semânticos e cálculo dos vetores de 3.072 dimensões, persistidos no banco vetorial.

O Quadro 2 sintetiza o balanço quantitativo da curadoria 2FA.

Quadro 2 – Balanço do processo de curadoria 2FA

Categoria de Destino	Volume	Justificativa Técnica e Destinação
Fontes Brutas Coletadas	164	Totalidade de vídeos publicados em 2026 no perfil auditado.
Descartes do Fator 1	47	Publicidades comerciais alheias ao escopo de lazer (óticas, lojas).
Retidos em Quarentena (Fator 2)	24	Locais sem endereço auditável no DF ou sem preço especificado.
Base Curada Aprovada (2FA)	**93**	**Homologados com endereço, coordenadas GPS, preço e vibes.**

Fonte: elaborado pelos autores (2026).

3 ESTRATÉGIA DE CHUNKING SEMÂNTICO CENTRADO EM ENTIDADE

A definição do método de divisão de texto (*chunking*) constitui um dos fatores mais determinantes para o sucesso de um sistema RAG. Vídeos curtos de recomendação (com duração entre 30 e 60 segundos) apresentam uma dinâmica narrativa peculiar: o nome do local é anunciado nos primeiros segundos; os destaques de ambiente e cardápio são apresentados no miolo; e os detalhes de localização, funcionamento e preço são enunciados no fechamento do vídeo.

Caso fosse aplicado um particionamento cego por tamanho fixo (*fixed-size chunking*) baseado em contagem de caracteres ou tokens, as coordenadas geográficas e os preços seriam fatalmente separados do nome do estabelecimento em blocos distintos. Essa fragmentação comprometeria a recuperação semântica e induziria o modelo a associar valores de um restaurante ao nome de outro, gerando alucinações.

Diante disso, adotou-se o Chunking Semântico Centrado em Entidade (*Entity-Centric Structured Semantic Chunking*). Nessa abordagem, cada documento aprovado pela curadoria 2FA corresponde rigorosamente a um único chunk autocontido, sintetizando quatro dimensões de informação:

1. **Identidade e Tipologia (Fator 1):** Nome oficial do estabelecimento e categoria de rolê;
2. **Ancoragem Geoespacial e Financeira (Fator 2):** Região Administrativa, endereço completo, coordenadas geográficas e custo médio estimado por pessoa;
3. **Atmosfera e Vocabulário Cultural (Fator 1):** Conjunto de etiquetas de clima (*vibes*), sinalização de ambiente infantil (*Kid Friendly*) e resumo sensorial da experiência;
4. **Evidência Oral Transcrita (Whisper):** Fragmento literal da locução falada no vídeo (até 500 caracteres), preservando termos específicos de cardápio citados pelo autor (como rodízio, feijoada, parrilla, brinquedoteca ou artesanal).

A estrutura padronizada de cada documento indexado segue o molde textual:

Local: {nome} | Categoria: {tipo} | Região: {regiao} ({endereco}) | Faixa de Preço: {faixa} (R$ {custo}) | Vibes: {vibes} | Experiência: {resumo} | Relato do TikTok: {transcricao}

4 ESTRATÉGIA DE EMBEDDINGS E BANCO VETORIAL

Para converter os chunks semânticos em representações numéricas comparáveis, selecionou-se o modelo *models/gemini-embedding-001*, da Google Generative Language API, configurado com dimensionalidade densa de 3.072 valores em ponto flutuante por coordenada.

A escolha do modelo fundamenta-se em três pilares:

a) **Domínio do Português Brasileiro:** Elevada capacidade de generalização sobre termos coloquiais e equivalências semânticas típicas do vocabulário de lazer no DF (por exemplo, correlacionando "passeio iluminado para crianças" ao evento infantil "Vale Encantado", ou "doce sem culpa" a sobremesas sem adição de açúcar refinado);

b) **Alta Resolução em 3.072 Dimensões:** Espaço vetorial amplo o suficiente para separar atmosferas contrastantes (como ambientes intimistas para encontros românticos versus espaços agitados com música ao vivo para grandes grupos);

c) **Eficiência e Escalabilidade:** Recuperação determinística de alta precisão com custo de consulta nulo na operação cotidiana.

A comparação entre o vetor da consulta formulada pelo usuário e cada um dos 93 documentos indexados no banco de dados é calculada através da métrica de Similaridade de Cosseno, definida pela fórmula matemática:

$$\text{Similaridade}(\vec{q},\vec{d}) = \frac{\vec{q}\cdot\vec{d}}{\|\vec{q}\|\|\vec{d}\|} = \frac{\sum_{i=1}^{n} q_i d_i}{\sqrt{\sum_{i=1}^{n} q_i^2}\sqrt{\sum_{i=1}^{n} d_i^2}} \tag{1}$$

Os 93 vetores de 3.072 dimensões encontram-se persistidos nos arquivos *data/banco_vetorial_embeddings.json* e *data/banco_vetorial_embeddings.csv*. O motor de recuperação implementado em *src/rag/banco_vetorial.py* carrega os dados em memória e executa a ordenação vetorial completa em menos de 10 milissegundos, selecionando os três estabelecimentos com maior pontuação semântica (Top-3).

5 ARQUITETURA DO PROTÓTIPO DE RAG E GUARDRAILS DE ESCOPO

O fluxo de processamento do protótipo de RAG opera segundo o paradigma de Geração Fundamentada (*Grounded Generation*), dividindo-se em duas camadas:

1. **Camada de Recuperação (Retriever):** A pergunta em linguagem natural submetida pelo usuário é vetorizada no mesmo espaço de 3.072 dimensões. Em seguida, o motor calcula a similaridade de cosseno contra todos os 93 locais curados e seleciona os três primeiros classificados.

2. **Camada de Síntese e Guardrails (Generator):** O modelo gerador recebe os três chunks recuperados inseridos em um prompt com instrução restritiva estrita. O modelo é impedido

de inventar estabelecimentos ou alterar valores: sua função é redigir uma recomendação coesa, citando explicitamente as fontes com o marcador [FONTE #X], endereço, preço e justificativa baseada nos atributos auditados.

Para lidar com consultas atípicas ou fora de escopo, implementaram-se dois guardrails de salvaguarda:

- *Guardrail de Escopo Regional:* Caso a consulta solicite rolês fora do Distrito Federal (por exemplo, em outros estados), o sistema rejeita a solicitação e esclarece que a base é exclusiva de Brasília e cidades satélites;
- *Guardrail de Alta Madrugada:* Como a base de 93 locais curados foca prioritariamente em gastronomia, cafés, passeios culturais e bares de *happy hour*, o sistema emite uma nota de escopo para perguntas de baladas de alta madrugada (após 01h00), indicando com transparência os estabelecimentos que funcionam até mais tarde (como o New Mercadito, aberto até 01h30, e o Carmelita, até 00h00) e evitando sugerir locais familiares com brinquedoteca.

6 DEMONSTRAÇÃO EXPERIMENTAL E EVIDÊNCIAS DE TESTE

Para comprovar o funcionamento pleno do pipeline, submeteu-se o sistema a três casos de teste oficiais com diferentes perfis de público e requisitos. A execução contemplou integralmente os quatro passos exigidos no edital: (1) Consulta submetida, (2) Recuperação dos chunks e scores, (3) Resposta sintetizada fundamentada e (4) Evidência e rastreabilidade das fontes com links originais do TikTok.

O Quadro 3 resume os três casos de demonstração auditados.

Quadro 3 – Resultados da demonstração experimental do RAG

Caso	Consulta Submetida	Recomendação	Cosseno	Preço	Destaque / Vibe
#1	Passeio iluminado/parque com crianças até R$ 30	Nicolândia / Vale Encantado	0.7205	R$ 29,90	Kid Friendly, parque infantil, acessível
#2	Hamburgueria artesanal animada no Sudoeste ou Taguatinga	Cabiburger / Filomenamburger	0.7151	R$ 50,00	Feito na brasa, rodízio variado, animado
#3	Confeitaria/gelateria zero açúcar e calma na Asa Sul	Lefit Gelatos e Doces Saudáveis	0.7763	R$ 28,00	Sem trigo, lactose nem açúcar refinado, calmo

Fonte: elaborado pelos autores (2026).

A seguir, transcrevem-se os detalhes comprobatórios de cada caso:

6.1 Caso de Demonstração #1 – Passeio Infantil Econômico

- **Consulta Submetida:** “Quero levar meus filhos pequenos num passeio iluminado ou parque tranquilo gastando até 30 reais por pessoa”.
- **Chunks Recuperados (Top-3):**
  - 1º Nicolândia Parque Urbano (Score: 0.7205; ID: *tiktok_7622722061256920327*; RA: Plano Piloto – Parque da Cidade).
  - 2º Vale Encantado (Score: 0.6923; ID: *tiktok_7698914646354447634*; RA: Taguatinga).
  - 3º Wellness Life Expo (Score: 0.6851; ID: *tiktok_7688858178133527816*; RA: Plano Piloto).
- **Resposta Fundamentada (RAG):** Recomenda o Nicolândia Parque Urbano [FONTE #1] no Parque da Cidade (R$ 29,90) por combinar brinquedos infantis com áreas ao ar livre, e o Vale Encantado [FONTE #2] em Taguatinga (R$ 19,90), enfatizando que ambas as opções cumprem o teto de R$ 30,00 e possuem brinquedoteca monitorada e atmosfera familiar. A terceira fonte (Wellness Life Expo) foi descartada por ultrapassar o limite financeiro (R$ 35,00).
- **Evidência e Rastreabilidade das Fontes:**
  - **[FONTE #1] Nicolândia Parque Urbano:** ID *tiktok_7622722061256920327*; GPS (-15.80126, -47.91021); Preço validado: R$ 29,90; Transcrição Whisper: *“...ingressos a partir de 29 e 90 para aproveitar o parque inteiro com as crianças...”*; Link: https://www.tiktok.com/@rolezandoembrasilia/video/7622722061256920327.
  - **[FONTE #2] Vale Encantado:** ID *tiktok_7698914646354447634*; GPS (-15.833, -48.056); Preço validado: R$ 19,90; Transcrição Whisper: *“...experiência temática familiar com túnel de luzes e show de neve por 19,90...”*; Link: https://www.tiktok.com/@rolezandoembrasilia/video/7698914646354447634.

6.2 Caso de Demonstração #2 – Hambúrguer Artesanal com Amigos

- **Consulta Submetida:** “Hamburgueria artesanal animada para ir com a galera no Sudoeste ou Taguatinga”.
- **Chunks Recuperados (Top-3):**
  - 1º Cabiburger (Score: 0.7151; ID: *tiktok_7670312298690481415*; RA: Plano Piloto / Sudoeste).
  - 2º Filomenamburger (Score: 0.7034; ID: *tiktok_7688864663336963336*; RA: Taguatinga Norte).
  - 3º House Burger (Score: 0.6989; ID: *tiktok_7698914666063432968*; RA: Riacho Fundo).

- **Resposta Fundamentada (RAG):** Para hambúrguer grelhado na brasa de carvão no Sudoeste, recomenda o Cabiburger [FONTE #1] (preço médio de R$ 50,00). Para grupos que buscam rodízio variado em ambiente descontraído em Taguatinga, indica o Filomenamburger [FONTE #2] (preço médio de R$ 50,00 com buffet de mini hambúrgueres e sobremesas). O House Burger [FONTE #3] oferece opção econômica no Riacho Fundo (R$ 30,00).

- **Evidência e Rastreabilidade das Fontes:**

  - **[FONTE #1] Cabiburger:** ID *tiktok_7670312298690481415*; GPS (-15.79616, -47.91498); Preço validado: R$ 50,00; Transcrição Whisper: *"...não tem hambúrguer na chapa, é feito direto na brasa com carvão de verdade..."*; Link: https://www.tiktok.com/@rolezandoembrasilia/video/7670312298690481415.

  - **[FONTE #2] Filomenamburger:** ID *tiktok_7688864663336963336*; GPS (-15.833, -48.056); Preço validado: R$ 50,00; Transcrição Whisper: *"...rodízio variado com mini hambúrgueres e sobremesa na cascata de cheddar..."*; Link: https://www.tiktok.com/@rolezandoembrasilia/video/7688864663336963336.

6.3 Caso de Demonstração #3 – Confeitaria Saudável e Ambiente Calmo

- **Consulta Submetida:** "Procuro uma confeitaria ou gelateria com opções zero açúcar ou saudáveis na Asa Sul para conversar com calma".

- **Chunks Recuperados (Top-3):**

  - 1º Lefit Gelatos e Doces Saudáveis (Score: 0.7763; ID: *tiktok_7699233720657530119*; RA: Plano Piloto – Asa Sul).

  - 2º Oficina de Tortas (Score: 0.7166; ID: *tiktok_7645713289552481543*; RA: Plano Piloto – Asa Sul).

  - 3º The Coffee Talk (Score: 0.7009; ID: *tiktok_7600076848222997767*; RA: Sudoeste).

- **Resposta Fundamentada (RAG):** Indica a Lefit Gelatos e Doces Saudáveis [FONTE #1] (preço médio de R$ 28,00), destacando que a casa é uma confeitaria e gelateria autoral com receitas livres de trigo, lactose e açúcar refinado, oferecendo ambiente intimista com baixo nível de ruído, perfeito para conversas tranquilas. A Oficina de Tortas [FONTE #2] (R$ 23,50) complementa como opção artesanal na Asa Sul.

- **Evidência e Rastreabilidade das Fontes:**

  - **[FONTE #1] Lefit Gelatos e Doces Saudáveis:** ID *tiktok_7699233720657530119*; GPS (-15.8192, -47.8988); Preço validado: R$ 28,00; Transcrição Whisper: *"...onde você come diversas delícias sem peso na consciência... tudo sem conservantes e sem açúcar refinado..."*; Link: https://www.tiktok.com/@rolezandoembrasilia/video/7699233720657530119.

– **[FONTE #2] Oficina de Tortas:** ID *tiktok_7645713289552481543*; GPS (-15.8192, -47.8988); Preço validado: R$ 23,50; Transcrição Whisper: *"...confeitaria mais artesanal de Brasília no aniversário com fatias especiais..."*; Link: https://www.tiktok.com/@rolezandoembrasilia/video/7645713289552481543.

7 TELEMETRIA, LLMOPS E AUDITORIA DE REQUISITOS NÃO FUNCIONAIS

A fim de assegurar prontidão operacional para o ambiente de produção, o sistema foi integrado à plataforma de observabilidade *Langfuse Cloud (versão 5.x)*. Cada consulta processada dispara automaticamente um fluxo de rastreamento (*trace*) subdividido em dois *spans*: (1) span de recuperação vetorial (*retriever*) e (2) span de geração e síntese (*generation*).

A auditoria matemática contínua monitora três Requisitos Não Funcionais prioritários:

1. **RNF-03 (Fidelidade Semântica e Zero Alucinação):** Métrica avaliada com nota 1.0 (100% de ancoramento). Todo o conteúdo das respostas é estritamente restrito aos 93 estabelecimentos catalogados pela curadoria 2FA.

2. **RNF-14 (SLA de Latência):** O edital estabelece teto máximo de 2,5 segundos para retorno da busca. As medições em regime contínuo registraram latência entre 7,1 ms e 21,9 ms, operando com margem de segurança superior a 100 vezes o limite estipulado.

3. **RNF-15 (Governança de Custos e Consumo de Tokens):** O consumo médio por requisição situa-se em aproximadamente 380 tokens totais (entrada e saída), correspondendo a um custo estimado de R$ 0,0035 por busca, o que viabiliza mais de 30.000 consultas gratuitas mensais no plano operacional.

O Quadro 4 apresenta as métricas consolidadas de observabilidade.

Quadro 4 – Métricas de telemetria e requisitos não funcionais (RNF)

Métrica de Telemetria	Requisito Associado	Meta Estipulada	Resultado Homologado
Fidelidade Factual	RNF-03 (Zero Alucinação)	Mínimo de 85%	**1.0 (100% das fontes auditadas no DF)**
Latência Total da Busca	RNF-14 (SLA de Resposta)	Menor que 2.500 ms	**7,1 ms a 21,9 ms (Conforme)**
Custo Médio por Consulta	RNF-15 (Custo Operacional)	Baixo Custo	**R$ 0,0035 por requisição (380 tokens)**
Dimensionalidade Vetorial	RNF-12 (Arquitetura)	Alta Resolução	**3.072 coordenadas densas (Gemini)**
Base de Dados Ativa	Requisito Semana 2	Mínimo de 20 fontes	**93 documentos oficiais auditados**

Fonte: elaborado pelos autores (2026).

Todos os dados curados, artefatos vetoriais, código-fonte e o protótipo funcional encontram-se disponíveis e podem ser avaliados de forma interativa diretamente no endereço web do projeto: https://orquestrador-roles.onrender.com/entregaveis.

REFERÊNCIAS

BARBOSA, Simone Diniz Junqueira et al. **Interação humano-computador e experiência do usuário**. [S. l.]: Autopublicação, 2021.

BRASIL. **Lei nº 13.709, de 14 de agosto de 2018**. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União: seção 1, Brasília, DF, 15 ago. 2018.

COOPER, Alan. **The inmates are running the asylum: why high tech products drive us crazy and how to restore the sanity**. Indianapolis: Sams Publishing, 1999.

COURAGE, Catherine; BAXTER, Kathy. **Understanding your users: a practical guide to user requirements methods, tools, and techniques**. San Francisco: Morgan Kaufmann, 2005.

LEWIS, Patrick et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. **Advances in Neural Information Processing Systems**, v. 33, p. 9459-9474, 2020.

RADFORD, Alec et al. Robust speech recognition via large-scale weak supervision. In: **International Conference on Machine Learning**. PMLR, 2023. p. 28492-28518.