Relatório Técnico: Base de Conhecimento, Protótipo de RAG e Telemetria

RES IA ELD UNB — Turma 2 | Grupo 7 — Orquestrador de Rolês (Brasília/DF)

Equipe: Letícia Miti Takahashi (Engenharia de Dados & RAG) e Maria Eduarda (DevOps, Infraestrutura & LLMOps)

Prazo Oficial: 09/11/2026, às 08h00 | **Demonstração Online:** https://orquestrador-roles.onrender.com | **Painel Langfuse:** Langfuse Cloud

---

1. Resumo Executivo e Checklist dos Artefatos

O objetivo deste entregável da Semana 2 é construir e auditar o primeiro mecanismo de **RAG (Retrieval-Augmented Generation)** fundamentado em base de conhecimento curada de Brasília, assegurando qualidade na recuperação, fundamentação sem alucinações e rastreabilidade total das fontes.

Requisito do Edital	Status	Localização no Repositório	Resumo Técnico
1. Base de conhecimento curada	Concluído	`data/banco_aprovado_2fa.json` e `.csv`	93 estabelecimentos aprovados pelo protocolo 2FA.
2. Mínimo de 20 documentos-fonte	Superado	`data/banco_aprovado_2fa.json` (93 fontes)	164 vídeos de 2026 do `@rolezandoembrasilia` (TikTok).
3. Estratégia de chunking	Concluído	Seção 2 + `src/rag/banco_vetorial.py`	*Entity-Centric Semantic Chunking* (1 chunk autocontido por local).
4. Estratégia de embeddings	Concluído	Seção 3 + `src/rag/banco_vetorial.py`	`models/gemini-embedding-001` (3.072 dimensões) + Similaridade Cosseno.
5. Banco vetorial implementado	Concluído	`data/banco_vetorial_embeddings.json`	93 vetores persistidos com busca por similaridade K=3.
6. Demonstração completa	Concluído	`src/rag/prototipo_rag.py` + `DEMONSTRACAO_RAG_ENTREGAVEL.txt`	4 passos: Consulta ➔ Chunks ➔ Resposta Fundamentada ➔ Fontes.
7. Diagrama & Pipeline	Concluído	Seções 4 e 5 deste relatório	Fluxogramas de Ingestão 2FA e Arquitetura de Runtime RAG.
8. Telemetria e LLMOps	Concluído	Seção 6 + `src/telemetria/telemetria.py`	Langfuse Cloud v5.x (Auditoria RNF-03 Zero Alucinação e RNF-14 Latência).

---

2. Estratégia de Chunking (*Entity-Centric Semantic Chunking*)

2.1. Por que não utilizar *Fixed-Size Chunking*?

Vídeos curtos (30 a 60 segundos) apresentam estrutura narrativa não linear: o **nome** é citado no início, as **vibes** no meio e o **preço e endereço** nos segundos finais. Um particionamento cego por tamanho fixo (caracteres/tokens) fragmentaria endereço e preço do nome do estabelecimento, provocando *context fragmentation* e alucinações.

2.2. Solução Adotada: 1 Documento-Fonte = 1 Chunk Autocontido

Cada registro aprovado consolida 4 camadas de informação em um único chunk semântico estruturado:

1. **Identidade e Categoria (Fator 1):** Nome oficial e tipo (`Restaurante`, `Bar/Pub`, `Cafeteria`, `Evento`, `Ao Ar Livre`).
2. **Ancoragem Geoespacial e Financeira (Fator 2):** Região Administrativa (RA), endereço validado, coordenadas GPS e faixa de preço (`Barato $`, `Moderado $$`, `Caro $$$`) com valor médio em R$.
3. **Atmosfera e Cultura (Fator 1):** Tags de *Vibes* (`Romântico`, `Calmo`, `Baratinho`, `Alternativo`, `Kid Friendly`, `Animado`) + Resumo Sensorial.
4. **Evidência Oral Bruta (Whisper):** Transcrição real do áudio falado (até 500 caracteres) preservando termos de cardápio (ex.: *"rodízio"*, *"parrilla"*, *"brinquedoteca"*).

Template do Chunk Indexado:

```
Local: {nome} | Categoria: {tipo} | Região: {RA} ({endereco}) | Preço: {faixa} (R$ {custo}) | Vibes: {vibes} | Experiência: {resumo} | TikTok: {audio_whisper}
```

---

3. Estratégia de Embeddings e Banco Vetorial

- **Modelo:** `models/gemini-embedding-001` (Google Generative Language API).

- **Dimensionalidade: 3.072 dimensões** (vetores densos de alta resolução).
- **Justificativa:** Excelente compreensão semântica do Português Brasileiro e gírias/regionalismos de Brasília (associações como *"passeio ao ar livre com criança"* ➔ *"Eixão do Lazer / Kid Friendly"*).
- **Métrica de Busca:** Similaridade de Cosseno:

```
Similaridade(q, d) = (q · d) / (||q|| × ||d||)
```

- **Persistência:** 93 vetores persistidos em `data/banco_vetorial_embeddings.json` e `.csv`, permitindo recuperação instantânea em memória (K=3).

---

4. Pipeline de Ingestão de Dados (Curadoria em 2 Fatores - 2FA)

Para impedir propagandas e registros incompletos, criamos um pipeline com **Autenticação de Dois Fatores de Dados (2FA)** em `src/rag/coletor_tiktok_2fa.py`:

1. Coleta Bruta (TikTok 2026): 164 vídeos do `@rolezandoembrasilia` → Extração MP3 (`yt-dlp` + `curl_cffi`) → Transcrição ASR via Groq (`whisper-large-v3-turbo`).

↓

2. FATOR 1 — Curadoria Cultural (LLM): É local real de lazer/gastronomia?
• *Não (47 vídeos):* Descartados automaticamente (óticas, colchões, roupas).
• *Sim (117 vídeos):* Extração de Nome, Categoria (5 tipos) e Vibes (7 tags).

↓

3. FATOR 2 — Validação Prática (Dupla Trava): Possui Endereço no DF + Faixa de Preço (R$)?
• *Incompleto (24 vídeos):* Retidos em Quarentena (`data/fila_quarentena_2fa.json`).
• *Aprovado nas 2 Travas (93 fontes):* Base Curada 2FA (`data/banco_aprovado_2fa.json`).

↓

4. Chunking Semântico & Vetorização: Chunks Autocontidos + Embeddings Google `gemini-embedding-001` (3.072-d) → Persistência no Banco Vetorial (`data/banco_vetorial_embeddings.json`).

---

5. Arquitetura do Sistema e Telemetria em Tempo de Execução

O diagrama abaixo ilustra o fluxo de dados em runtime com observabilidade contínua via **Langfuse Cloud (v5.x)**:

Pipeline Online de Recuperação e Geração Aumentada (Runtime RAG)

1. Consulta & Vetorização	**2. Busca Vetorial (Top-3)**	**3. Geração Fundamentada**
Pergunta em linguagem natural vetorizada em 3.072-d via `gemini-embedding-001`.	Cálculo de Cosseno sobre os 93 chunks curados no Banco Vetorial.	LLM sintetiza resposta ancorada nos chunks + links TikTok e GPS.

Telemetria e Observabilidade em Tempo Real (Langfuse Cloud v5.x / OpenTelemetry)
Rastreamento dos spans `retriever` e `generation` com auditoria contínua dos RNFs: `fidelidade_rnf03_zero_alucinacao = 1.0`, `sla_latencia_rnf14 ≤ 5.0s` e `qualidade_recuperacao_rag`.

---

6. Telemetria, Observabilidade e Auditoria de RNFs (Langfuse Cloud)

A instrumentação ponta a ponta com **Langfuse Cloud (v5.x)** (`src/telemetria/telemetria.py`) audita matematicamente o pipeline a cada requisição:

1. **`fidelidade_rnf03_zero_alucinacao` (Meta: Zero Alucinação) — Score Obtido: 1.0 (100% ancorado):** O validador garante que todas as recomendações pertencem estritamente aos 93 documentos do `data/banco_aprovado_2fa.json`.
2. **`sla_latencia_rnf14` (Meta ≤ 5.0s) — Score Obtido: 1.0 (Conforme):** Latência média de processamento entre **2.8 ms e 21.9 ms**, operando com mais de 200x de margem de segurança.
3. **`qualidade_recuperacao_rag` (Relevância Semântica) — Score Obtido: 0.87 a 0.98:** Atesta alta precisão no casamento da intenção com os metadados e áudios.

6.1. Casos de Teste Auditados com Traces Rastreáveis no Langfuse:

ID	Consulta Submetida	1º Lugar Recuperado	Região	Cosseno	Latência	Trace ID no Langfuse
#1	*"Qual o melhor boteco alternativo e animado na Asa Sul?"*	**Spelunca DF**	Asa Sul	**0.98**	21.9 ms	`ac2ece1889e84b72`

#2	*"Quero um café romântico e calmo na Asa Norte"*	**Café e Um Chêro**	Asa Norte	**0.98**	5.5 ms	`2fe411a5e04f46ab`
#3	*"Opção ao ar livre, baratinha e kid friendly para domingo"*	**Eixão do Lazer**	Eixo Rodov.	**0.87**	2.8 ms	`0a0f08b4188045f1`

6.2. Análise Técnica e Qualitativa dos Resultados

- **Desambiguação Semântica (Caso #1):** Ao solicitar "boteco alternativo na Asa Sul", o modelo descartou cafeterias da Asa Norte e priorizou o *Spelunca DF* (Score 0.98), respeitando o filtro de tipo e o recorte geográfico.
- **Captura de Nuances de Atmosfera (Caso #2):** A transcrição de áudio do Whisper capturou menções a café intimista e aconchegante, garantindo que o *Café e Um Chêro* liderasse o ranking com 0.98 de aderência.
- **Filtros Multifatoriais (Caso #3):** A combinação de lazer aberto, gratuidade (*baratinho*) e adequação familiar ativou as tags `Kid Friendly` e `Ao Ar Livre`, ranqueando o *Eixão do Lazer* no topo.

6.3. Governança de Custos e Consumo de Tokens (RNF-15)

- **Tokens Médios de Entrada:** ~280 tokens por consulta (Prompt estruturado + Top-3 Chunks recuperados).
- **Tokens Médios de Saída:** ~65 tokens por consulta (Resposta direta e fundamentada com fontes).
- **Custo Estimado por Requisição: $0.000045 USD** utilizando o modelo Google Gemini 1.5 Flash.
- **Sustentabilidade Operacional:** Com esses parâmetros, a cota gratuita mensal suporta mais de 30.000 buscas sem custos para a UnB ou para o Instituto Eldorado.

---

7. Demonstração e Como Testar o Protótipo

7.1. Opção 1: Demonstração Online Direta no Navegador (Recomendada)

Acesse a aplicação em produção: **https://orquestrador-roles.onrender.com**

- Permite submeter perguntas, visualizar os cards com links do TikTok e conferir os metadados de telemetria e o link do trace no Langfuse em tempo real.

7.2. Opção 2: Bateria de Testes via Terminal

Execute na raiz do projeto:

```
python3 src/rag/prototipo_rag.py
```

O comando executa os **4 passos obrigatórios**:

1. Exibe a **Consulta submetida**;
2. Exibe os **Top-3 Chunks recuperados** com seus scores de cosseno;
3. Exibe a **Resposta fundamentada da LLM** citando `[FONTE #1]`, `[FONTE #2]`;
4. Lista a **Evidência das Fontes** (ID, GPS, preço validado, transcrição Whisper e URL do TikTok).

(O log completo de saída encontra-se salvo em `docs/entregas/semana-02/DEMONSTRACAO_RAG_ENTREGAVEL.txt`).

---

8. Preparação para a Semana 3 (Baseline LLM pura vs. RAG)

Conforme o cronograma pedagógico do Challenge 2, a **Semana 3** terá como foco a comparação empírica entre respostas de modelos sem contexto (*LLM pura*) e respostas ancoradas (*RAG baseado em evidências*). A safra de 93 rolês auditados e o tracing instrumentado no Langfuse já estabelecem a **linha de base quantitativa (Baseline)** necessária para comprovar a eliminação de alucinações e a assertividade geoespacial no Distrito Federal.

8.1. Metodologia do Benchmark Comparativo (Golden Dataset)

Para a Semana 3, foi estruturado um conjunto de 10 perguntas de teste com diferentes graus de complexidade e especificidade regional:

1. **Perguntas de Nicho Local:** Testar estabelecimentos pouco conhecidos fora de Brasília para avaliar se a LLM pura inventa ruas ou quadras fictícias.
2. **Perguntas Multifatoriais de Preço e Horário:** Avaliar a fidelidade aos valores médios (R$) e dias de funcionamento (ex: eventos de domingo no Eixão).
3. **Métricas de Avaliação no Langfuse:** Cada par de respostas (*LLM Pura* vs. *RAG*) será comparado via LLM-as-a-Judge no Langfuse considerando:

- **Fidelidade Factual (Hallucination Rate):** Percentual de afirmações verificáveis no banco 2FA;
- **Precisão de Endereçamento:** Verificação se as quadras e RA indicadas existem e correspondem ao local;
- **Rastreabilidade:** Presença de links e transcrições comprovando a sugestão.

8.2. Matriz de Tratamento de Casos de Borda e Guardrails do RAG

Cenário de Borda	Comportamento Observado	Mecanismo de Salvaguarda (Guardrail)
Consulta Fora de Escopo *(ex: "Onde jantar em Copacabana?")*	Similaridade de cosseno máxima inferior ao limiar mínimo (Score < 0.65).	O sistema rejeita educadamente alucinar e sinaliza que a base curada é exclusiva do Distrito Federal.
Restrições Conflitantes *(ex: "Restaurante de luxo grátis")*	Recupera itens com semântica de gastronomia sofisticada, mas valida o metadado `faixa_preco`.	A LLM avisa explicitamente que a categoria solicitada opera na faixa `$$$` ou `$$$$`, sugerindo alternativas.
Gírias Regionais Candangas *(ex: "dar um rolê na tesourinha")*	O embedding de 3.072 dimensões associa vocabulário oral do Whisper à geografia local.	Assegura que contextos informais encontrem locais pertinentes sem falha de recuperação lexical.

---

9. Conclusão e Links de Acesso ao Ecossistema

A entrega da Semana 2 cumpre integralmente os requisitos do Segundo Desafio: **volume curado comprovado** (93 fontes contra meta mínima de 20), **chunking semântico estruturado**, **embeddings de 3.072 dimensões**, **respostas rastreáveis sem alucinação**, **observabilidade completa com Langfuse** e **orçamento viável**, atestando qualidade e conformidade com os requisitos da Residência em IA (UnB / Instituto Eldorado).

Recurso do Projeto	Tipo de Acesso	Endereço / Identificador
Aplicação Web (Produção)	Nuvem pública (Render)	`https://orquestrador-roles.onrender.com`
Interface Interativa do RAG	Nuvem pública (Render)	`https://orquestrador-roles.onrender.com/rag`
Painel Langfuse (Observabilidade)	Langfuse Cloud v5	Projeto `cmw59be2y01d8ad0jqbgsjut6`
Demonstração em Terminal (Logs)	Repositório	`docs/entregas/semana-02/DEMONSTRACAO_RAG_ENTREGAVEL.txt`
Pacote Compactado da Entrega	Arquivo ZIP	`docs/entregas/semana-02/Entregavel_Grupo7_Base_Conhecimento_e_RAG.zip`